lista

Lucas Matheus - 211029049

2022-04-21

Questão 1

Com base no banco de dados nycflights13::flights, execute os comandos a seguir, a fim de transformar o banco de dados em uma lista por companhia aerea (carrier), e responda os itens abaixo utilizando a lista banco e as funcionalidades do pacotepurr.

```
banco <- nycflights13::flights%>% split(.$carrier)
```

a) A partir da listabanco, selecione as colunas que contém a palavra 'delay' para cada companhia aerea(carrier). Retorne o resultado como uma lista.

```
lista<-map(banco,~select(., ends_with("delay")))
lista</pre>
```

```
## $'9E'
   # A tibble: 18,460 x 2
##
##
      dep_delay arr_delay
##
           <dbl>
                      <dbl>
##
    1
               0
                          11
    2
              -9
                          -2
##
##
    3
              -3
                          -2
              -6
##
    4
                          -1
##
    5
              -8
                          -5
               0
                          -5
##
    6
    7
               6
                           5
##
               0
##
    8
                          13
              -8
##
    9
                          -8
## 10
              -6
                         -33
##
   # ... with 18,450 more rows
##
## $AA
   # A tibble: 32,729 x 2
##
##
      dep_delay arr_delay
##
           <dbl>
##
               2
    1
                          33
##
    2
              -2
                           8
    3
              -1
                          31
##
##
              -4
                         -12
```

```
##
   5
              13
                         5
##
   6
              -2
                        -3
##
   7
              -1
                        14
##
   8
               0
                        48
##
    9
              -4
                         4
## 10
              -3
                       -10
## # ... with 32,719 more rows
##
## $AS
## # A tibble: 714 x 2
      dep_delay arr_delay
##
          <dbl>
                     <dbl>
##
   1
              -1
                       -10
##
   2
              -7
                       -19
##
    3
              -3
                       -41
               3
##
    4
                         1
##
    5
              -1
                       -18
##
    6
               2
                        -9
##
    7
               0
                         1
              -7
##
    8
                       -29
##
   9
               0
                       -19
## 10
             -12
                       -12
## # ... with 704 more rows
##
## $B6
## # A tibble: 54,635 \times 2
##
      dep_delay arr_delay
##
          <dbl>
                     <dbl>
##
                       -18
   1
             -1
##
    2
              -5
                        19
##
    3
              -3
                        -8
##
    4
              -2
                        -2
##
    5
              -2
                        -3
##
               0
                        -4
    6
                        -7
##
    7
               0
##
    8
               1
                        -6
##
   9
               3
                         4
## 10
               0
                       -21
## # ... with 54,625 more rows
##
## $DL
## # A tibble: 48,110 \times 2
##
      dep_delay arr_delay
##
          <dbl>
                     <dbl>
##
   1
              -6
                       -25
##
    2
              -8
                        -8
##
    3
              -4
                        -8
##
                        -9
    4
               0
##
    5
              -7
                       -33
##
    6
              0
                        -9
##
   7
              -5
                        -8
##
   8
              -5
                       -18
##
  9
             -3
                       -14
## 10
              -2
                         5
```

```
## # ... with 48,100 more rows
##
## $EV
## # A tibble: 54,173 x 2
##
     dep_delay arr_delay
##
          <dbl>
                   <dbl>
## 1
            -3
                     -14
## 2
            -6
                       29
## 3
             24
                       12
## 4
            -6
                      -7
## 5
            -4
                     -26
## 6
            -2
                      23
## 7
            -8
                      -2
## 8
            -4
                     -18
## 9
             0
                      -4
## 10
              0
                      -14
## # ... with 54,163 more rows
##
## $F9
## # A tibble: 685 x 2
##
     dep_delay arr_delay
##
          <dbl>
                   <dbl>
## 1
            -2
                       32
## 2
            -14
                       -6
            -8
## 3
                       18
## 4
            -2
                      -1
## 5
             0
                       0
## 6
            123
                       98
## 7
                       -3
            -1
## 8
            61
                       36
## 9
                       -5
             0
## 10
            -4
                       -5
## # ... with 675 more rows
##
## $FL
## # A tibble: 3,260 x 2
##
     dep_delay arr_delay
##
          <dbl>
                   <dbl>
## 1
            -3
                       10
## 2
             4
                       17
## 3
            -2
                       2
## 4
            -8
                       8
## 5
            -10
                       -5
## 6
            -3
                       6
## 7
            -8
                        6
## 8
             0
                       14
## 9
            -11
                       2
## 10
            -10
                       -7
## # ... with 3,250 more rows
##
## $HA
## # A tibble: 342 x 2
      dep_delay arr_delay
##
##
          <dbl>
                   <dbl>
```

```
##
             -3
                       -14
   1
##
    2
              9
                        -5
##
    3
              14
                        -26
##
    4
              0
                       -14
              -2
##
    5
                        -11
##
    6
             79
                        28
##
    7
             102
                        50
                       -26
##
    8
               1
##
    9
           1301
                      1272
## 10
              -1
                       -41
   # ... with 332 more rows
##
## $MQ
## # A tibble: 26,397 \times 2
##
      dep_delay arr_delay
##
          <dbl>
                     <dbl>
##
    1
              0
                        12
##
    2
              -3
                        16
##
              8
                        32
    3
##
              -6
                        10
    4
             -9
##
    5
                        27
##
    6
             39
                        49
##
    7
             -10
                        -6
##
    8
             -10
                        -4
##
    9
             101
                        137
## 10
             -4
                       -13
##
  # ... with 26,387 more rows
##
## $00
## # A tibble: 32 x 2
##
      dep_delay arr_delay
##
          <dbl>
                     <dbl>
##
   1
             67
                        107
##
                        -5
    2
              -6
                        27
##
    3
              13
##
    4
              -8
                        -24
##
    5
              4
                        -6
##
    6
               1
                         3
    7
              -9
##
                        -20
##
    8
             131
                        157
##
    9
             -10
                         3
             154
## 10
                        140
## # ... with 22 more rows
##
## # A tibble: 58,665 x 2
##
      dep_delay arr_delay
          <dbl>
##
                     <dbl>
##
               2
   1
                        11
##
    2
               4
                        20
##
    3
              -4
                        12
             -2
##
   4
                         7
##
   5
             -2
                       -14
##
    6
              -1
                        -8
```

```
## 7
             0
                     -17
## 8
             11
                       14
## 9
             -4
                       1
## 10
            -2
                       29
## # ... with 58,655 more rows
##
## $US
## # A tibble: 20,536 x 2
##
      dep_delay arr_delay
##
          <dbl>
                    <dbl>
## 1
            -8
                        3
## 2
             -3
                       0
## 3
             -1
                       -9
## 4
            -2
                     -11
## 5
            -7
                      -4
## 6
             -4
                       10
            -2
## 7
                      -5
## 8
            -7
                      -29
## 9
            -5
                      11
## 10
            -1
                      -15
## # ... with 20,526 more rows
## $VX
## # A tibble: 5,162 x 2
      dep_delay arr_delay
          <dbl>
                   <dbl>
## 1
            -2
                       2
## 2
             -1
                      -26
## 3
                      -2
            -1
## 4
              2
                      -6
## 5
                      -22
              1
## 6
             3
                      -2
## 7
             3
                      -26
## 8
             -3
                     -17
## 9
             -3
                      -40
## 10
             0
                      -5
## # ... with 5,152 more rows
##
## $WN
## # A tibble: 12,275 x 2
      dep_delay arr_delay
##
          <dbl>
                   <dbl>
## 1
             -1
                      -19
## 2
            -1
                       33
## 3
             -3
                       26
## 4
                       30
             4
## 5
             -2
                      15
## 6
            -3
                       7
## 7
            -1
                      -14
## 8
             -5
                       5
## 9
             -2
                       -4
             0
                       23
## 10
## # ... with 12,265 more rows
##
```

```
## $YV
## # A tibble: 601 x 2
##
      dep_delay arr_delay
         <dbl>
##
                    <dbl>
##
   1
             -7
                      -20
##
  2
           -11
                      -23
##
  3
            -5
                      -13
## 4
             89
                      75
            -8
##
   5
                      -15
   6
            -5
##
                      -18
##
   7
             -6
                       -1
             -3
                      -22
##
  8
## 9
             -7
                        5
             -3
## 10
                      -16
## # ... with 591 more rows
```

```
class(lista)
```

```
## [1] "list"
```

b) A partir da lista obtida na letra A, calcule a média dos atrasos de chegada e de saída para cada companhia aerea (carrier). Retorne o resultado como um dataframe.

```
arr <- lista %>%
  lapply(function(x) x = x$arr_delay)%>%
  map_dfc(mean, na.rm = T)
arr<- as.data.frame(t(arr))

dep <- lista %>%
  lapply(function(x) x = x$dep_delay)%>%
  map_dfc(mean, na.rm = T)
dep<-as.data.frame(t(dep))

arr_dep<-cbind(arr,dep)
arr_dep</pre>
```

```
## V1 V1
## 9E 7.3796692 16.725769
## AA 0.3642909 8.586016
## AS -9.9308886 5.804775
## B6 9.4579733 13.022522
## DL 1.6443409 9.264505
## EV 15.7964311 19.955390
## F9 21.9207048 20.215543
## FL 20.1159055 18.726075
## HA -6.9152047 4.900585
```

```
## MQ 10.7747334 10.552041

## 00 11.9310345 12.586207

## UA 3.5580111 12.106073

## US 2.1295951 3.782418

## VX 1.7644644 12.869421

## WN 9.6491199 17.711744

## YV 15.5569853 18.996330
```

c) Crie uma função para repetir a tarefa da letra B, mas permita ao usuário escolher a operação que seráefetuada nas colunas (média, mínimo, summary, etc...). Permita ao usuário escolher se na.rm = T/F.Retorne o resultado como uma lista.

```
function(lista,operação,TF){
    arr <- lista %>%
    lapply(function(x) x = x$arr_delay)%>%
    map_dfc(mean, na.rm = T)
arr<- as.data.frame(t(arr))%>%
    rename(arr = V1)

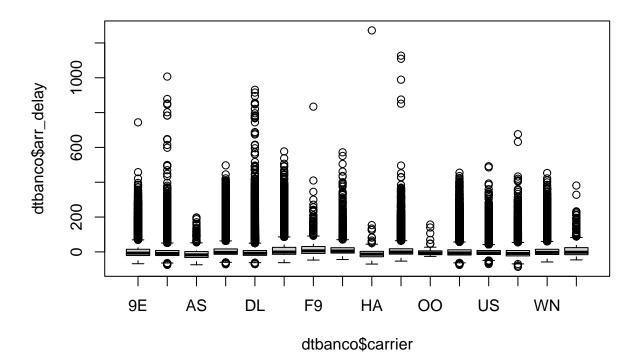
dep <- lista %>%
    lapply(function(x) x = x$dep_delay)%>%
    map_dfc(mean, na.rm = T)
dep<-as.data.frame(t(dep))%>%
    rename(dep = V1)

arr_dep<-cbind(arr,dep)
    return(as.list(df))
}</pre>
```

```
## function(lista, operação, TF) {
##
       arr <- lista %>%
##
     lapply(function(x) x = x$arr_delay)%>%
     map_dfc(mean, na.rm = T)
##
## arr<- as.data.frame(t(arr))%>%
##
     rename(arr = V1)
##
## dep <- lista %>%
     lapply(function(x) x = x$dep_delay)%>%
##
     map_dfc(mean, na.rm = T)
##
## dep<-as.data.frame(t(dep))%>%
     rename(dep =V1)
##
##
## arr_dep<-cbind(arr,dep)</pre>
      return(as.list(df))
## }
```

d)A partir da lista inicial banco, faça um boxplot da coluna 'arr_delay' para cada companhia aérea (utilizeas funçõesmapeboxplot).

```
x <- as.list(banco)
dtbanco <-map_df(x,~.x)
y <- boxplot(dtbanco$arr_delay~dtbanco$carrier)</pre>
```



e)Note que, além do gráfico, a função boxplot retorna uma série de informações relevantes. Com base nisso,retorne quantos outliers na variável 'arr_delay' cada companhia aérea registrou. Retorne o resultado como um vetor

```
limitesup <- quantile(dtbanco$arr_delay,0.975, na.rm = TRUE)
limiteinf <- quantile(dtbanco$arr_delay,0.025, na.rm = TRUE)
x <-which(dtbanco$arr_delay < limiteinf | dtbanco$arr_delay > limitesup)
```

Questão 2

Usando uma cópia da base de dados 'lahmansbaseballdb.sqlite' em formato SQLite (fontehttp://www.seanlahman.com/baseball-archive/statistics/), responda usando a linguagem SQL:

```
conmy = dbConnect(RSQLite::SQLite(),db = "lahmansbaseballdb.sqlite")
conmy
```

```
## <SQLiteConnection>
## Path: C:\Users\Lucas\Documents\lahmansbaseballdb.sqlite
## Extensions: TRUE
```

a) Liste as 10 maiores porcentagens de rebatidas por tentativa (batting average). Batting average pode sercalculada dividindo o número de rebatidas (hits, coluna H na tabela Batting) pelo número de tentativas (at-bats, coluna AB na tabela Batting). Inclua o nome do jogador e o ano de ocorrência, além da porcentagematingida. Elimine dos cálculos os jogadores com menos de 50 tentativas.

```
dbListFields(conmy, "batting")
                                  "yearID"
##
    [1] "ID"
                     "playerID"
                                              "stint"
                                                           "teamID"
                                                                        "team ID"
                     "G"
                                                                        "H"
    [7] "lgID"
                                  "G batting" "AB"
                                                           "R"
## [13] "2B"
                     "3B"
                                  "HR"
                                              "RBI"
                                                           "SB"
                                                                        "CS"
                     "SO"
                                  "IBB"
                                              "HBP"
                                                                        "SF"
## [19] "BB"
                                                           "SH"
## [25] "GIDP"
dbListFields(conmy, "people")
##
    [1] "playerID"
                          "birthYear"
                                            "birthMonth"
                                                              "birthDay"
##
    [5] "birthCountry"
                          "birthState"
                                            "birthCity"
                                                              "deathYear"
   [9] "deathMonth"
                          "deathDay"
                                            "deathCountry"
                                                              "deathState"
                          "nameFirst"
## [13] "deathCity"
                                            "nameLast"
                                                              "nameGiven"
## [17] "weight"
                          "height"
                                            "bats"
                                                              "throws"
## [21] "debut"
                                            "retroID"
                          "finalGame"
                                                              "bbrefID"
## [25] "birth date"
                          "debut date"
                                            "finalgame date" "death date"
dbGetQuery(conmy, statement=
               "SELECT batting.H*100 / batting.AB AS battingaverage, people.nameFirst, batting.yearID
                       FROM batting, people
                       WHERE batting.AB >= 50 AND batting.playerID=people.playerID
                       GROUP BY people.nameFirst, batting.yearID
                       ORDER BY battingaverage DESC
                       LIMIT 10")
##
      battingaverage nameFirst yearID
## 1
                   49
                           Levi
                                   1871
## 2
                   43
                            Cal
                                   1871
## 3
                   43
                           Hugh
                                   1894
                                   1872
## 4
                   43
                           Ross
## 5
                   43
                           Ross
                                   1873
## 6
                   43
                            Tip
                                  1887
## 7
                   42
                                   1923
                           Jack
## 8
                   42
                            Nap
                                   1901
## 9
                   42
                         Rogers
                                   1924
## 10
                   42
                           Ross
                                   1876
```

b)Liste as 10 maiores porcentagens de rebatidas por tentativa (batting average). Inclua o nome do jogador,o ano de ocorrência e o nome do college/school (obtido da tabela 'collegeplaying') que o jogador estava noano, além da porcentagem atingida. Elimine dos cálculos os jogadores com menos de 50 tentativas.

```
##
      battingaverage nameFirst yearID
                                        schoolID
## 1
                  40
                        Hughie
                                 1896
                                         stbonny
## 2
                  39
                          Fred
                                 1894
                                            brown
## 3
                  39
                          Ryan
                                 2005
                                        virginia
                  38
## 4
                         Frank
                                 1884
                                         cornell
## 5
                  38
                        Hughie
                                 1895
                                          stbonny
                          John
## 6
                  36
                                 1895
                                          stbonny
                  35
                        Hughie
                                 1897
## 7
                                          stbonny
## 8
                  35
                          John
                                 1928 mryvilletn
## 9
                  33
                         Jimmy
                                 1893 holycross
## 10
                  33
                          John
                                 1894
                                          stbonny
```

c)

```
valores <- function(dad, digits = 2) {</pre>
  dad <- dad %>%
    na.omit()
  valores <- data.frame(</pre>
   Valores = c(
      mean(dad),
      sd(dad),
      var(dad),
      min(dad),
      max(dad),
      quantile(dad,.5),
    )
  )
  rownames(valores) <- c(</pre>
    "Média", "Desvio Padrão", "variância",
    "Mediana", "Máximo",
    "Máximo"
  )
```

```
return(valores)
}
```

d) Liste as 5 college/school com maiores MÉDIAS de porcentagens de rebatidas por tentativa (média daescola com base nos jogadores que estavam jogando lá no ano). Inclua o nome do college/school (obtidoda 'collegeplaying') e a porcentagem média atingida. Elimine dos cálculos os jogadores com menos de 50 tentativas.

```
dbGetQuery(conmy, statement=
     "SELECT AVG(batting.H*100 / batting.AB) AS battingaverage, collegeplaying.schoolID
     FROM batting, collegeplaying
     WHERE collegeplaying.playerID = batting.playerID AND batting.yearID = collegeplaying.year
     GROUP BY collegeplaying.schoolID, batting.yearID, collegeplaying.playerID
     ORDER BY battingaverage DESC
     LIMIT 5")
```

e) Dentre as college/school com maiores MÉDIAS de porcentagens de rebatidas por tentativa (média daescola com base nos jogadores que estavam jogando lá no ano), liste aquelas que tem University no nome(10 melhores). Inclua o nome do college/school (obtido da 'collegeplaying') e a porcentagem média atingida. Elimine dos cálculos os jogadores com menos de 50 tentativas.

```
dbGetQuery(conmy, statement=
    "SELECT AVG(batting.H*100 / batting.AB) AS battingaverage, schools.name_full
    FROM batting, schools, collegeplaying
    WHERE batting.AB >= 50 AND schools.name_full LIKE '%University%' AND collegeplaying.school GROUP BY collegeplaying.schoolID, batting.yearID, collegeplaying.playerID
    ORDER BY battingaverage DESC
    LIMIT 10")
```

```
##
      battingaverage
                                       name_full
## 1
                  40 St. Bonaventure University
## 2
                  39
                               Brown University
## 3
                  39
                         University of Virginia
## 4
                  38 St. Bonaventure University
## 5
                  36 St. Bonaventure University
## 6
                  35 St. Bonaventure University
## 7
                  33 St. Bonaventure University
                          University of Alabama
## 8
                  32
## 9
                  32
                          Georgetown University
## 10
                  32 St. Bonaventure University
```

Questão 3

Usando uma cópia da base de dados 'lahmansbaseballdb.sqlite' em formato SQLite (fontehttp://www.seanlahman.com/baseball-archive/statistics/), responda usando a linguagem SQL:

```
conmy = dbConnect(RSQLite::SQLite(),db = "lahmansbaseballdb.sqlite")
conmy

## <SQLiteConnection>
## Path: C:\Users\Lucas\Documents\lahmansbaseballdb.sqlite
## Extensions: TRUE
```

a) Liste o jogador com maior salário de cada ano

```
yearID max(salary) playerID
##
                  2130300 schmimi01
## 1
        1985
## 2
        1986
                  2800000 fostege01
## 3
        1987
                  2127333 schmimi01
## 4
                  2340000 smithoz01
        1988
## 5
        1989
                  2766667 hershor01
                  3200000 yountro01
## 6
        1990
## 7
                  3800000 strawda01
        1991
## 8
        1992
                  6100000 bonilbo01
## 9
        1993
                  6200000 bonilbo01
## 10
        1994
                  6300000 bonilbo01
                  9237500 fieldce01
## 11
        1995
## 12
        1996
                  9237500 fieldce01
## 13
                 10000000 belleal01
        1997
## 14
        1998
                 14936667 sheffga01
## 15
                 11949794 belleal01
        1999
## 16
                 15714286 brownke01
        2000
## 17
        2001
                 22000000 rodrial01
## 18
        2002
                 22000000 rodrial01
## 19
        2003
                 22000000 rodrial01
## 20
        2004
                 22500000 ramirma02
## 21
                 26000000 rodrial01
        2005
## 22
        2006
                 21680727 rodrial01
## 23
        2007
                 23428571 giambja01
## 24
        2008
                 28000000 rodrial01
## 25
        2009
                 33000000 rodrial01
## 26
                 33000000 rodrial01
        2010
## 27
        2011
                 32000000 rodrial01
## 28
                 30000000 rodrial01
        2012
## 29
        2013
                 29000000 rodrial01
## 30
        2014
                 26000000 greinza01
## 31
        2015
                 32571000 kershcl01
## 32
        2016
                 33000000 kershcl01
```

b) Acrescente a idade do jogador na planilha da letra A

```
dbGetQuery(conmy, statement=
    "SELECT AVG(batting.H*100 / batting.AB) AS battingaverage, schools.name_full
    FROM batting, schools, collegeplaying
    WHERE batting.AB >= 50 AND schools.name_full LIKE '%University%' AND collegeplaying.school GROUP BY collegeplaying.schoolID, batting.yearID, collegeplaying.playerID
    ORDER BY battingaverage DESC
    LIMIT 10")
```

```
##
      battingaverage
                                       name_full
## 1
                  40 St. Bonaventure University
## 2
                  39
                                Brown University
## 3
                  39
                         University of Virginia
## 4
                  38 St. Bonaventure University
## 5
                  36 St. Bonaventure University
## 6
                  35 St. Bonaventure University
## 7
                  33 St. Bonaventure University
## 8
                  32
                          University of Alabama
## 9
                  32
                          Georgetown University
## 10
                  32 St. Bonaventure University
```

c) Filtre os jogadores com idade igual ou maior do que 30 anos na planilha da letra B. Comente o resultado.

```
dbGetQuery(conmy,statement =
    "SELECT salaries.playerID, salaries.yearID, 2016-people.birthYear AS idade
    FROM people, salaries
    WHERE idade >=30 AND salaries.playerID=people.playerID
    GROUP BY salaries.yearID
    HAVING MAX(salary)")
```

```
##
      playerID yearID idade
     schmimi01
                  1985
## 1
                          67
                          68
## 2
     fostege01
                  1986
## 3
     schmimi01
                  1987
                          67
     smithoz01
## 4
                  1988
                          62
## 5
     hershor01
                  1989
                          58
## 6 yountro01
                  1990
                          61
## 7 strawda01
                 1991
                          54
## 8
     bonilbo01
                  1992
                          53
## 9 bonilbo01
                  1993
                          53
## 10 bonilbo01
                 1994
                          53
## 11 fieldce01
                  1995
                          53
## 12 fieldce01
                  1996
                          53
## 13 belleal01
                  1997
                          50
## 14 sheffga01
                  1998
                          48
## 15 belleal01
                  1999
                          50
## 16 brownke01
                  2000
                          51
## 17 rodrial01
                  2001
                          41
```

```
## 18 rodrial01
                  2002
                           41
## 19 rodrial01
                  2003
                           41
## 20 ramirma02
                  2004
                           44
## 21 rodrial01
                  2005
                           41
## 22 rodrial01
                  2006
                           41
## 23 giambja01
                  2007
                           45
## 24 rodrial01
                   2008
                           41
## 25 rodrial01
                  2009
                           41
## 26 rodrial01
                  2010
                           41
## 27 rodrial01
                  2011
                           41
## 28 rodrial01
                  2012
                           41
## 29 rodrial01
                  2013
                           41
## 30 greinza01
                  2014
                           33
## 31 verlaju01
                           33
                   2015
## 32 greinza01
                  2016
                           33
```